

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN



BÁO CÁO MÔN HỌC

HỆ HỖ TRỢ QUYẾT ĐỊNH

Mã môn học: MI4216

Đề tài: Mô hình phân lớp hành vi mua hàng của khách

Giáo viên môn học: TS. Trần Ngọc Thắng

Sinh viên thực hiện: Hoàng Mạnh Đức

Mã số sinh viên: 20237311

Lớp: 169316

Hà Nội, Tháng 04 năm 2026

Mục lục

1	Giới thiệu bài toán	5
1.1	Bối cảnh	5
1.2	Lý do chọn đề tài	5
1.3	Đối tượng sử dụng hệ thống	5
2	Mục tiêu hỗ trợ ra quyết định	6
2.1	Quyết định phân bổ ngân sách khuyến mãi	6
2.2	Quyết định tối ưu hóa chiến dịch Quảng cáo bám đuôi	6
2.3	Quyết định can thiệp hỗ trợ thời gian thực	7
3	Mô tả và tiền xử lý dữ liệu	7
3.1	Nguồn dữ liệu	7
3.2	Ý nghĩa các biến ban đầu	7
3.3	Kiểm tra và Đánh giá chất lượng dữ liệu	9
3.4	Làm sạch dữ liệu	10
3.5	Trích xuất đặc trưng	11
4	Khám phá dữ liệu	13
4.1	Phân bố dữ liệu của nhãn	13
4.2	Phân bố dữ liệu các đặc trưng	14
4.3	So sánh RFM giữa hai nhãn	19
4.4	Hành vi mua hàng so với các đặc trưng thời gian	21
4.5	Mối tương quan giữa các đặc trưng	22
5	Huấn luyện mô hình	24
5.1	Mục tiêu mô hình	24
5.2	Xây dựng mô hình	24
6	Kết quả và đánh giá	26
6.1	Kết quả mô hình cơ sở	26
6.2	Mô hình Random Forest	27
6.3	Mô hình sử dụng Gradient Boosting	29
6.4	Tổng hợp kết quả	31
7	Khuyến nghị ra quyết định	31
7.1	Khuyến nghị	31
7.2	Đánh giá Rủi ro và Hạn chế của hệ thống	33
8	Hạn chế và hướng phát triển	34
8.1	Hạn chế của dữ liệu và mô hình hiện tại	34
8.2	Hướng phát triển trong tương lai	35
9	Phân công công việc	36

10 Sử dụng AI	37
11 Minh chứng	37

Danh sách hình vẽ

1	Kiểm tra kiểu dữ liệu bằng Python	9
2	Kiểm tra null bằng Python	9
3	Kiểm tra trùng lặp bằng Python	10
4	Kiểm tra thống kê dữ liệu	10
5	Làm sạch dữ liệu thô	11
6	Phân bố hai nhân	14
7	Biểu đồ phân đặc trưng total view	14
8	Biểu đồ phân đặc trưng total cart	15
9	Biểu đồ phân đặc trưng total remove	15
10	Biểu đồ phân đặc trưng avg price	16
11	Biểu đồ phân đặc trưng unique brand	16
12	Biểu đồ phân đặc trưng unique product	17
13	Biểu đồ phân đặc trưng session duration	17
14	Biểu đồ phân đặc trưng max price	18
15	Biểu đồ so sánh R Score	19
16	Biểu đồ so sánh F Score	19
17	Biểu đồ so sánh M Score	20
18	Biểu đồ so sánh RFM Score	20
19	Biểu đồ tỷ lệ mua hàng theo giờ	21
20	Biểu đồ tỷ lệ mua hàng ngày trong tuần	21
21	Hệ số tương quan giữa các biến	23
22	Biểu đồ ROC	26
23	ROC của mô hình Random Forest	27
24	Đồ thị ROC của LightGBM	30

Danh sách bảng

1	Từ điển dữ liệu nguyên bản (Raw Event Logs)	8
2	5 dòng dữ liệu sau trích xuất	13
3	Báo cáo kết quả phân loại	27
4	Báo cáo kết quả phân loại	28
5	Báo cáo kết quả phân loại	30
6	Bảng tổng hợp so sánh hiệu suất giữa các mô hình (Chọn ngưỡng tối ưu Recall)	31
7	Bảng phân công công việc của các thành viên trong nhóm . .	36

1 Giới thiệu bài toán

1.1 Bối cảnh

Trong kỷ nguyên số hóa, Thương mại điện tử (TMĐT) đang trải qua giai đoạn bùng nổ, thay đổi hoàn toàn thói quen mua sắm của người tiêu dùng. Tuy nhiên, một nghịch lý đang diễn ra trong ngành bán lẻ trực tuyến: Lượng truy cập (Traffic) nền tảng rất cao, nhưng tỷ lệ chuyển đổi (Conversion Rate) lại thấp. Theo các báo cáo ngành, tỷ lệ "bỏ rơi giỏ hàng" (Cart Abandonment Rate) trung bình lên tới gần 70%. Cùng lúc đó, các hệ thống TMĐT lưu trữ một lượng dữ liệu khổng lồ dưới dạng Nhật ký sự kiện (Event Logs), ghi lại từng cú click chuột của khách hàng. Đây là cơ sở dữ liệu quan trọng để ứng dụng Học máy nhằm "đọc vị" ý định của người dùng trong thời gian thực.

1.2 Lý do chọn đề tài

Đề tài "Dự đoán ý định mua hàng của người dùng trên nền tảng Thương mại điện tử" được lựa chọn dựa trên hai động lực chính:

- **Về mặt kinh doanh:** Các chiến dịch Marketing hiện tại thường phân phối mã giảm giá đại trà, gây lãng phí ngân sách và giảm biên lợi nhuận. Việc dự đoán chính xác ai sẽ mua hàng giúp doanh nghiệp tối ưu hóa chi phí và chuyển hướng sang Marketing cá nhân hóa (Targeted Marketing).
- **Về mặt kỹ thuật:** Khai thác dữ liệu sự kiện thô (Raw Event Logs) là một thách thức lớn đối với bài toán Học máy. Quá trình này đòi hỏi kỹ thuật trích xuất đặc trưng (Feature Engineering) phức tạp để chuyển hóa hành vi lướt web thành các chỉ số định lượng, đồng thời phải kiểm soát chặt chẽ vấn đề rò rỉ dữ liệu (Data Leakage).

1.3 Đối tượng sử dụng hệ thống

Mô hình dự đoán được thiết kế nhằm phục vụ trực tiếp cho các phòng ban cốt lõi của doanh nghiệp TMĐT:

1. **Bộ phận Marketing:** Tối ưu hóa ngân sách quảng cáo bám đuôi (Retargeting) và tự động hóa việc phân phối Voucher kích cầu chuyên biệt cho nhóm khách hàng "đang phân vân", từ đó nâng cao chỉ số hoàn vốn (ROI).
2. **Bộ phận Chăm sóc khách hàng (CSKH):** Phát hiện các phiên truy cập có nguy cơ rời đơn hàng ở bước thanh toán để tiến hành can thiệp thời gian thực (ví dụ: kích hoạt Pop-up Live Chat tư vấn).
3. **Bộ phận UI/UX và Phát triển sản phẩm:** Tùy biến giao diện (Dynamic UI) dựa trên ý định của khách hàng. Nếu khách hàng có ý định mua cao, hệ thống sẽ tinh gọn giao diện, làm nổi bật các thao tác thanh toán nhanh.

2 Mục tiêu hỗ trợ ra quyết định

Kết quả phân tích và dự đoán từ mô hình Học máy không chỉ mang ý nghĩa thống kê mà còn đóng vai trò là "la bàn" định hướng cho các chiến lược vận hành của doanh nghiệp. Cụ thể, mô hình hỗ trợ ba nhóm quyết định kinh doanh cốt lõi sau đây:

2.1 Quyết định phân bổ ngân sách khuyến mãi

- **Quyết định cần hỗ trợ:** Doanh nghiệp có nên cấp phát mã giảm giá (Voucher), ưu đãi miễn phí vận chuyển (Freeship) cho một khách hàng cụ thể trong phiên truy cập hiện tại hay không? Mức giảm giá nên là bao nhiêu?
- **Người ra quyết định:** Giám đốc Tiếp thị (CMO), Trưởng nhóm Vận hành Khuyến mãi, hoặc Hệ thống tự động hóa tiếp thị (Marketing Automation System).
- **Kết quả phân tích giúp ra quyết định như thế nào?** Thay vì "rải" mã giảm giá đại trà gây thâm hụt ngân sách, kết quả dự đoán xác suất mua hàng từ mô hình giúp hệ thống chia khách hàng làm 3 nhóm để tự động ra quyết định:
 - *Nhóm chắc chắn mua (Xác suất > 80%):* Khách hàng đã có ý định rõ ràng. Quyết định: **Không tặng Voucher** nhằm bảo vệ biên lợi nhuận (Profit Margin) tối đa.
 - *Nhóm đang phân vân (Xác suất 40% - 80%):* Khách hàng đã thêm đồ vào giỏ nhưng chần chừ chưa thanh toán. Quyết định: **Tặng Voucher giới hạn thời gian (Pop-up 10 phút)** để tạo hiệu ứng tâm lý sợ bỏ lỡ (FOMO), ép khách hàng chốt đơn.
 - *Nhóm không có ý định mua (Xác suất < 40%):* Chỉ lướt xem giá. Quyết định: **Không tặng Voucher** để tránh lãng phí.

2.2 Quyết định tối ưu hóa chiến dịch Quảng cáo bám đuôi

- **Quyết định cần hỗ trợ:** Có nên đưa tệp khách hàng vừa thoát khỏi website vào chiến dịch chạy quảng cáo bám đuôi (Retargeting) trên các nền tảng như Facebook, Google hay không?
- **Người ra quyết định:** Chuyên viên Quảng cáo (Performance Marketer), Quản lý Digital Marketing.
- **Kết quả phân tích giúp ra quyết định như thế nào?** Chạy quảng cáo hiển thị lại cho toàn bộ 100% người từng truy cập website là một bài toán đốt tiền. Mô hình phân loại sẽ chấm điểm (Scoring) và lọc ra danh sách Top 20% khách hàng có xác suất mua cao nhất nhưng chưa thanh

toán. Người chạy quảng cáo sẽ sử dụng tệp dữ liệu tinh gọn này để đẩy lên Facebook/Google, giúp tiết kiệm chi phí thu hút khách hàng (CAC - Customer Acquisition Cost) và tăng vọt chỉ số Lợi tức đầu tư quảng cáo (ROAS).

2.3 Quyết định can thiệp hỗ trợ thời gian thực

- **Quyết định cần hỗ trợ:** Có nên chủ động tiếp cận, mở cửa sổ tư vấn (Live-chat) hoặc gọi điện thoại trực tiếp cho khách hàng ngay lúc này không?
- **Người ra quyết định:** Trưởng bộ phận Chăm sóc khách hàng (CS Manager), Nhân viên hỗ trợ trực tuyến (Live Agent).
- **Kết quả phân tích giúp ra quyết định như thế nào?** Hệ thống liên tục đánh giá hành vi lướt web. Nếu mô hình nhận diện một phiên truy cập có "điểm ý định mua" rất cao (khách đã thêm sản phẩm đắt tiền vào giỏ), nhưng khách lại dừng quá 3 phút ở trang thanh toán, hệ thống sẽ phát tín hiệu cảnh báo. Lúc này, nhân viên CSKH ra quyết định **chủ động nhắn tin**: *"Chào bạn, tôi thấy bạn đang gặp khó khăn ở bước thanh toán, bạn có cần hỗ trợ về phí vận chuyển không?"*. Sự can thiệp đúng lúc này giúp "cứu vớt" những giỏ hàng bị bỏ rơi do lỗi kỹ thuật hoặc do khách hàng thắc mắc thông tin.

3 Mô tả và tiền xử lý dữ liệu

3.1 Nguồn dữ liệu

Tập dữ liệu sử dụng trong nghiên cứu này là **eCommerce Events History in Cosmetics Shop**, được công bố công khai trên nền tảng Kaggle. Dữ liệu ghi lại nhật ký sự kiện (Event logs) cấp độ thô của một sàn thương mại điện tử thực tế chuyên về mỹ phẩm trong khoảng thời gian từ tháng 10/2019 đến tháng 02/2020. Với quy mô hơn 20 triệu bản ghi (mỗi bản ghi tương ứng với một lượt tương tác của người dùng), tập dữ liệu phản ánh chính xác hành vi lướt web theo thời gian thực, là nền tảng lý tưởng để xây dựng mô hình dự đoán ý định mua hàng.

3.2 Ý nghĩa các biến ban đầu

Dữ liệu gốc (Raw data) được lưu trữ dưới dạng chuỗi sự kiện. Cấu trúc của mỗi bản ghi được mô tả chi tiết trong Bảng 1.

Bảng 1: Từ điển dữ liệu nguyên bản (Raw Event Logs)

Tên biến	Kiểu dữ liệu	Ý nghĩa và Giải thích
<code>event_time</code>	String	Thời điểm chính xác xảy ra sự kiện (Định dạng UTC).
<code>event_type</code>	String	Loại tương tác của người dùng. Bao gồm 4 giá trị: <code>view</code> (xem), <code>cart</code> (thêm giỏ), <code>remove_from_cart</code> (xóa khỏi giỏ), <code>purchase</code> (thanh toán).
<code>product_id</code>	int64	Mã định danh duy nhất của sản phẩm.
<code>category_id</code>	int64	Mã định danh của danh mục sản phẩm.
<code>category_code</code>	string	Tên chuỗi phân cấp danh mục (VD: <i>apparel.shoes</i>).
<code>brand</code>	string	Tên thương hiệu của sản phẩm.
<code>price</code>	Float64	Giá của sản phẩm (Đơn vị USD).
<code>user_id</code>	int64	Mã định danh duy nhất của khách hàng.
<code>user_session</code>	string	Mã phiên truy cập. Một khách hàng có thể có nhiều phiên truy cập khác nhau trong các khoảng thời gian khác nhau.

```
1 import pandas as pd
2
3 raw_data=pd.read_csv('Data/2019-Dec.csv')
4 raw_data.info()

<class 'pandas.DataFrame'>
RangeIndex: 3533286 entries, 0 to 3533285
Data columns (total 9 columns):
# column      dtype
...
0 event_time   str
1 event_type   str
2 product_id   int64
3 category_id  int64
4 category_code str
5 brand        str
6 price        float64
7 user_id      int64
8 user_session str
```

Hình 1: Kiểm tra kiểu dữ liệu bằng Python

3.3 Kiểm tra và Đánh giá chất lượng dữ liệu

Trước khi trích xuất đặc trưng, dữ liệu thô được kiểm tra toàn diện để phát hiện các điểm bất thường.

- **Kiểm tra kiểu dữ liệu (Data Types):** Cột `event_time` ban đầu được hệ thống đọc dưới dạng chuỗi văn bản (Object). Cần phải chuyển đổi sang định dạng `Datetime` để phục vụ cho việc tính toán thời lượng lướt web.
- **Kiểm tra Dữ liệu thiếu (Missing Values):** Các trường định danh giao dịch (như `user_session`, `event_type`, `price`) có tỷ lệ điền đầy 100%. Tuy nhiên, cột `brand` (thương hiệu) bị khuyết thiếu khoảng 42% và `category_code` bị khuyết hơn 98% nên ta có thể xóa cột `category_code`. Điều này phản ánh thực tế nghiệp vụ: rất nhiều sản phẩm giá rẻ, không có thương hiệu cụ thể được đăng bán trên sàn.

```
1 raw_data.isna().sum()/3533285*100

[5] 0.1s

... event_time      0.000000
    event_type      0.000000
    product_id      0.000000
    category_id      0.000000
    category_code  98.345336
    brand          42.744613
    price          0.000000
    user_id         0.000000
    user_session    0.022047
    dtype: float64
```

Hình 2: Kiểm tra null bằng Python

- **Kiểm tra Trùng lặp (Duplication):** Trong dữ liệu dạng Log, việc người dùng click đúp (double-click) chuột do lỗi mạng hoặc độ trễ giao diện dẫn đến các bản ghi giống hệt nhau đến từng mili-giây. Dữ liệu ghi nhận khoảng 5.2% các dòng bị trùng lặp hoàn toàn.

```
1 print(raw_data.duplicated().sum())
[7] ✓ 5.7s Python
... 183860

1 183860/3533285*100
[8] ✓ 0.0s Python
... 5.20365608774837
```

Hình 3: Kiểm tra trùng lặp bằng Python

- **Kiểm tra Ngoại lệ (Outliers):** Thống kê mô tả cột `price` cho thấy xuất hiện một số giá trị âm (< 0) do lỗi hệ thống backend, và một số sản phẩm có giá cao bất thường (lên tới hàng ngàn USD trong một cửa hàng mỹ phẩm), gây nhiễu cho mô hình.

```
1 raw_data.describe()
[9] ✓ 0.8s
```

	product_id	category_id	price	user_id
count	3.533286e+06	3.533286e+06	3.533286e+06	3.533286e+06
mean	5.473054e+06	1.555023e+18	8.871856e+00	5.223318e+08
std	1.331331e+06	1.689262e+17	1.986474e+01	8.494819e+07
min	3.752000e+03	1.487580e+18	-7.937000e+01	1.180452e+06
25%	5.726191e+06	1.487580e+18	2.060000e+00	4.866830e+08
50%	5.811429e+06	1.487580e+18	4.210000e+00	5.566496e+08
75%	5.859462e+06	1.487580e+18	7.140000e+00	5.828019e+08
max	5.917178e+06	2.235524e+18	3.277800e+02	5.954145e+08

Hình 4: Kiểm tra thống kê dữ liệu

3.4 Làm sạch dữ liệu

- **Xử lý trùng lặp và ngoại lệ:** Tiến hành loại bỏ hoàn toàn các dòng trùng lặp (Drop duplicates). Các bản ghi có `price` ≤ 0 bị loại bỏ vì không mang ý nghĩa kinh doanh. Các mặt hàng có giá lớn hơn phân vị thứ 99 (99th percentile) được giới hạn lại (Winsorization) để giảm tác động của nhiễu.

```

1 data = raw_data.drop_duplicates()
2 data=data[data['price']>=0]

```

[13] ✓ 9.9s Python

Xử lý ngoại lệ

```

1 gioi_han_99 = data['price'].quantile(0.99)
2 print(f"Giá trị bách phân vị 99: {gioi_han_99}")
3
4 data['price'] = data['price'].clip(upper=gioi_han_99)
5
6 data.describe()

```

[12] ✓ 0.8s Python

... Giá trị bách phân vị 99: 103.17

...

	product_id	category_id	price	user_id
count	3.349409e+06	3.349409e+06	3.349409e+06	3.349409e+06
mean	5.470482e+06	1.555165e+18	8.475992e+00	5.228340e+08
std	1.336454e+06	1.690827e+17	1.519136e+01	8.527801e+07
min	3.752000e+03	1.487580e+18	0.000000e+00	1.180452e+06
25%	5.726184e+06	1.487580e+18	2.060000e+00	4.875069e+08
50%	5.811422e+06	1.487580e+18	4.270000e+00	5.576702e+08
75%	5.859485e+06	1.487580e+18	7.140000e+00	5.830666e+08
max	5.917178e+06	2.235524e+18	1.031700e+02	5.954145e+08

Hình 5: Làm sạch dữ liệu thô

- **Xử lý dữ liệu thiếu:** Thay vì xóa bỏ các dòng thiếu **brand** (sẽ làm mất đi 42% lượng truy cập), các giá trị Null được điền bằng chuỗi *"Unknown"*. Việc một sản phẩm "Không có thương hiệu" bản chất cũng là một đặc trưng hành vi đáng giá để mô hình học tập. Bên cạnh đó ta loại bỏ các cột không đóng góp cho quá trình dự đoán như **category_code**. Sau đó ta loại bỏ các dòng có **user_session** bị null đi (chiếm khoảng 2.2%)

3.5 Trích xuất đặc trưng

1. **Thiết lập Biến mục tiêu (Target Variable):** Một phiên truy cập được gán nhãn $Y = 1$ (Có mua hàng) nếu trong phiên đó tồn tại ít nhất một sự kiện **purchase**. Ngược lại gán nhãn $Y = 0$.
2. **Xây dựng và chuẩn hóa đặc trưng Giá trị Khách hàng (RFM):** RFM được tính toán dựa trên lịch sử giao dịch toàn cục của người dùng (**user_id**) nhằm nắm bắt giá trị vòng đời khách hàng. Các chỉ số được trích xuất nghiêm ngặt từ các sự kiện mua hàng thành công:

- **R (Recency):** $R = T_{current} - \max(T_{purchase})$. Khoảng thời gian (tính bằng ngày) kể từ lần mua hàng cuối cùng.
- **F (Frequency):** $F = |\{S_{purchase}\}|$. Tổng số phiên giao dịch có phát sinh hành vi mua hàng.
- **M (Monetary):** $M = \sum Price_{purchase}$. Tổng giá trị chi tiêu trong quá khứ.

Chuẩn hóa thang điểm: Để đưa vào mô hình, dữ liệu thô được chia thành 4 nhóm bằng phương pháp **Tứ phân vị (Quartiles)**, quy đổi về thang điểm rời rạc từ 1 đến 4. Đặc biệt, khách hàng chưa từng mua hàng sẽ được gán điểm 0.

- **Điểm R:** Tỷ lệ nghịch với số ngày (Mua càng gần đây $\rightarrow$ Điểm càng cao, tối đa là 4).
 - **Điểm F & M:** Tỷ lệ thuận với giá trị (Tần suất/chi tiêu càng cao $\rightarrow$ Điểm càng cao). Thuật toán sử dụng kỹ thuật xếp hạng ưu tiên (*rank method = 'first'*) để cân bằng số lượng mẫu giữa các nhóm.
 - **Tổng điểm (RFM_Total_Score):** Tính bằng tổng 3 thành phần $R + F + M$, dao động từ 0 đến 12 điểm.
3. **Tách biệt dữ liệu (Ngăn chặn Leakage):** Toàn bộ các sự kiện **purchase** được gỡ bỏ khỏi tập huấn luyện. Mô hình chỉ được phép "nhìn" vào lịch sử **view**, **cart** để dự đoán.
4. **Tổng hợp đặc trưng (Aggregation):** Biến đổi dữ liệu thành các biến định lượng mới:
- *Đặc trưng Thời gian:* **day_of_week** (thứ trong tuần) và **hour_of_day** (giờ trong ngày) được trích xuất từ thời điểm bắt đầu phiên, giúp mô hình bắt được tính chu kỳ và thói quen mua sắm.
 - *Đặc trưng Hành vi:* **total_views** (tổng số lượt xem), **total_carts** (tổng lượt thêm giỏ), **total_removes** (tổng lượt xóa khỏi giỏ), **session_duration** (thời lượng phiên tính bằng giây).
 - *Đặc trưng Tiền tệ:* **avg_price**, **max_price** (mức giá trung bình và tối đa của các sản phẩm khách hàng tương tác trong phiên).
 - *Đặc trưng Đa dạng:* **unique_products** (số lượng sản phẩm khác nhau), **unique_brands** (số lượng thương hiệu khác nhau), cùng cờ **is_single_brand** xác định phiên chỉ tập trung vào một thương hiệu duy nhất.
 - *Đặc trưng Thương hiệu (Target Encoding):* Thương hiệu được quan tâm nhất trong phiên (**top_brand**) được mã hóa thành biến liên tục **top_brand_encoded** dựa trên tỷ lệ mua hàng trên số phiên của thương hiệu đó.

Bảng 2: 5 dòng dữ liệu sau trích xuất

user_session	day	hr	views	carts	rmvs	dur(s)	avg_p	max_p	1_brd
bfb1...105f	7	15	1	0	0	0	14.29	14.29	1
7a79...b958	7	9	1	0	0	0	7.14	7.14	1
50fb...8508	3	21	6	2	0	1292	5.49	15.48	0
6582...8711	6	15	1	0	0	0	13.13	13.13	1
16e6...5e78	5	9	7	0	0	545	3.73	18.89	0


user_session	u_prd	u_brd	R	F	M	RFM	enc_brd	is_purchased
bfb1...105f	1	1	0	0	0	0	0.039	0
7a79...b958	1	1	0	0	0	0	0.029	0
50fb...8508	6	2	2	3	2	7	0.039	0
6582...8711	1	1	0	0	0	0	0.035	0
16e6...5e78	7	3	0	0	0	0	0.039	0

4 Khám phá dữ liệu

Sau quá trình trích xuất đặc trưng (Feature Engineering), việc Phân tích dữ liệu khám phá (EDA) được thực hiện nhằm kiểm tra dữ liệu đã thích hợp để xây dựng mô hình chưa.

4.1 Phân bố dữ liệu của nhân

Ta sẽ vẽ đồ thị thể hiện số lượng hai nhân mà ta cần phân:




Hình 6: Phân bố hai nhãn


Kết luận: Từ đây ta thấy được 2 nhãn đang mất cân bằng nghiêm trọng sẽ ảnh hưởng lớn đến mô hình sau này.

4.2 Phân bố dữ liệu các đặc trưng


Ta sẽ vẽ đồ thị thể hiện mật độ các giá trị nằm trong mức phân vị thứ 98 của từng biến với hai lớp để so sánh:




Hình 7: Biểu đồ phân đặc trưng total view




Hình 8: Biểu đồ phân đặc trưng total cart




Hình 9: Biểu đồ phân đặc trưng total remove




Hình 10: Biểu đồ phân đặc trưng avg price




Hình 11: Biểu đồ phân đặc trưng unique brand



Hình 12: Biểu đồ phân đặc trưng unique product



Hình 13: Biểu đồ phân đặc trưng session duration



Hình 14: Biểu đồ phân đặc trưng max price


Từ biểu đồ này ta thấy được những nhận xét sau:

- Đặc điểm của nhóm "Bounce" (Khách hàng thoát trang nhanh)**
 Quan sát tại biểu đồ `total_views` và `unique_products`, phân phối của Lớp 0 (Không mua) tạo thành một cột cao đột biến (Spike) ngay tại giá trị bằng 1. Đi kèm với đó, `session_duration` của nhóm này cũng tập trung dày đặc ở sát mốc 0 giây. Điều này phác họa chân dung của tệp khách hàng "Click dạo" hoặc "Vào nhầm link": Họ nhấp vào xem đúng một sản phẩm duy nhất và lập tức thoát trang mà không có bất kỳ tương tác nào khác.
- "Thêm vào giỏ" và "Xóa khỏi giỏ" đều là tín hiệu tích cực** Biểu đồ `total_carts` cho thấy sự phân tách tuyệt đối: Nhóm mua hàng (Lớp 1) chiếm ưu thế hoàn toàn từ giá trị ≥ 1 . Đáng chú ý hơn, tại biểu đồ `total_removes`, phân phối của nhóm chốt đơn cũng trải dài về phía bên phải. Về mặt logic kinh doanh, điều này chứng minh rằng thao tác "Xóa sản phẩm khỏi giỏ hàng" không phải là một tín hiệu tiêu cực. Ngược lại, nó thể hiện sự cân nhắc, so sánh và chọn lọc kỹ lưỡng (Active Shopping) của những khách hàng thực sự có ý định mua sắm nghiêm túc.
- Quy trình so sánh sản phẩm** Biểu đồ `unique_products` của nhóm mua hàng có giá trị nằm phần lớn ở khoảng 2 đến 6 sản phẩm. Khách hàng hiếm khi mua ngay sản phẩm đầu tiên họ nhìn thấy. Họ có xu hướng xem nhiều mặt hàng khác nhau để so sánh trước khi đưa ra quyết định cuối cùng.
- Mức giá không quyết định ý định mua** Biểu đồ `avg_price` là trường hợp đặc biệt nhất khi phân phối của hai lớp 0 và 1 gần như chồng khít lên nhau. Cả hai nhóm đều tập trung xem các sản phẩm ở phân khúc


giá thấp và giảm dần ở phân khúc giá cao. Điều này mang lại một phát hiện kinh doanh giá trị: *Giá tiền của sản phẩm không phải là yếu tố phân loại việc khách có chốt đơn trong phiên đó hay không*. Ý định mua hàng được quyết định bởi **mức độ tương tác sâu** (số lượt xem, thời gian trên trang) chứ không phải bởi giá trị tuyệt đối của món hàng.

4.3 So sánh RFM giữa hai nhãn


Ta vẽ đồ thị giá trị trung bình từng đặc trưng theo nhãn như sau:




Hình 15: Biểu đồ so sánh R Score



Hình 16: Biểu đồ so sánh F Score



Hình 17: Biểu đồ so sánh M Score



Hình 18: Biểu đồ so sánh RFM Score


Nhận xét từ phân tích đặc trưng RFM: Qua biểu đồ so sánh giá trị trung bình của các chỉ số RFM theo biến mục tiêu, ta có thể rút ra những kết luận quan trọng sau:

- **Phân hóa dữ liệu rõ rệt:** Tồn tại sự chênh lệch lớn về giá trị lịch sử giữa hai nhóm. Khách hàng thực hiện giao dịch (Nhân 1) có tổng điểm RFM trung bình đạt 7.15, cao gấp 3.3 lần so với nhóm không giao dịch (Nhân 0, đạt 2.15).
- **Tính dự báo cao (Predictive Power):** Các chỉ số R, F, M độc lập đều cho thấy nhóm Nhân 1 có giá trị trung bình áp đảo (trên 2.2) so với nhóm Nhân 0 (chỉ ở mức 0.72). Sự tách biệt rạch ròi này chứng


minh RFM là nhóm đặc trưng có sức mạnh phân loại rất tốt, dự kiến sẽ đóng góp trọng số lớn (Feature Importance) trong việc giúp mô hình học máy đưa ra quyết định.

- **Ý nghĩa hành vi:** Dữ liệu phản ánh đúng thực tế kinh doanh rằng tỷ lệ chuyển đổi phụ thuộc lớn vào lòng trung thành của khách hàng. Những người dùng đã có tiền sử chi tiêu cao (M lớn), mua sắm thường xuyên (F lớn) và tương tác gần đây (R lớn) sẽ có xác suất tiếp tục mua hàng trong phiên hiện tại cao hơn hẳn so với người dùng mới.

4.4 Hành vi mua hàng so với các đặc trưng thời gian



Hình 19: Biểu đồ tỷ lệ mua hàng theo giờ



Hình 20: Biểu đồ tỷ lệ mua hàng ngày trong tuần

Khảo sát giá trị trung bình của nhân mục tiêu `is_purchased` theo các mốc thời gian cung cấp cái nhìn chi tiết về quy luật hoạt động của tập dữ liệu:


- **Đặc trưng hour_of_day (Tính chu kỳ trong ngày):** Dữ liệu thể hiện sự phân hóa rõ ràng theo trục thời gian. Xác suất xuất hiện

nhân dương đạt đỉnh vào khung giờ sáng (9 : 00 – 11 : 00), với giá trị cực đại là 0.037 tại mốc 10 : 00. Ngược lại, xác suất này chạm đáy (0.023 – 0.026) vào khung giờ đêm muộn và rạng sáng. Đặc điểm này mang lại lượng thông tin (Information Gain) hữu ích, giúp các thuật toán phân lớp nhận diện được ngữ cảnh truy cập mang mục đích giao dịch cao.

- **Đặc trưng day_of_week (Tính ổn định giữa các ngày):** Biểu đồ phân bố theo ngày trong tuần thể hiện trạng thái đi ngang với biên độ dao động cực kỳ hẹp (từ 0.028 đến 0.033). Sự thiếu hụt phương sai (Low Variance) giữa các nhóm cho thấy hành vi phát sinh giao dịch không bị phụ thuộc nhiều vào ngày trong tuần. Xét về mặt khai phá dữ liệu, đây là một đặc trưng yếu (Weak Predictor) và dự kiến sẽ đóng góp trọng số (Feature Importance) rất thấp vào kiến trúc mô hình tổng thể.
- **Kết luận nhóm đặc trưng:** Các biến thời gian đóng vai trò là đặc trưng ngữ cảnh (Contextual Features). Việc tích hợp `hour_of_day` kết hợp cùng các nhóm đặc trưng hành vi và RFM sẽ giúp mô hình bắt được những quy luật ẩn có tính không gian - thời gian, tuy nhiên không nên kỳ vọng đây là yếu tố phân loại chủ đạo.

4.5 Môi trường quan giữa các đặc trưng

Sau khi phân tích phân bố của dữ liệu ta đến với việc phân tích tương quan giữa các biến với nhau:



Hình 21: Hệ số tương quan giữa các biến

Phân tích ma trận tương quan giữa các đặc trưng cung cấp những góc nhìn quan trọng về cấu trúc dữ liệu trước khi đưa vào huấn luyện mô hình:

- **Hiện tượng đa cộng tuyến mạnh** : Xuất hiện các cụm đặc trưng mang thông tin chồng chéo lớn. Điển hình là nhóm chỉ số RFM (**R_Score**, **F_Score**, **M_Score**) có tương quan nội bộ đạt ngưỡng 0.85 – 0.97, và nhóm định giá (**avg_price**, **max_price**) đạt ngưỡng 0.92. Đặc điểm này đòi hỏi sự cẩn trọng nếu áp dụng các thuật toán tuyến tính, nhưng hoàn toàn phù hợp với các mô hình phi tuyến (Tree-based).
- **Sự thống nhất về hành vi duyệt web**: Cường độ tương tác tỷ lệ thuận với sự đa dạng của phiên. Đặc trưng **unique_products** biểu diễn tương quan dương mạnh với **total_carts** ($r = 0.82$) và **total_views** ($r = 0.65$). Ngược lại, biến **is_single_brand** xác nhận tính logic của dữ liệu khi có tương quan âm mạnh với số lượng thương hiệu (-0.71).
- **Đặc tính phi tuyến của bài toán** : So với biến mục tiêu **is_purchased**, toàn bộ các đặc trưng đầu vào đều chỉ ghi nhận mức độ tương quan tuyến tính yếu đến trung bình yếu (hệ số cao nhất là 0.26 tại **unique_brands**). Kết quả này khẳng định hành vi mua sắm không bị chi phối tuyến tính

bởi bất kỳ một yếu tố đơn lẻ nào. Do đó, việc xây dựng các mô hình Học máy phức tạp để nắm bắt các quy luật ẩn sâu đa chiều là bước đi mang tính bắt buộc để giải quyết bài toán này.

5 Huấn luyện mô hình

5.1 Mục tiêu mô hình

Mục tiêu cốt lõi của bước này là xây dựng một hệ thống phân loại nhị phân (Binary Classification) có khả năng dự đoán chính xác việc một phiên truy cập (Session) có dẫn đến hành vi thanh toán (Purchase) hay không. Do tính chất đặc thù mất cân bằng nghiêm trọng của dữ liệu Thương mại điện tử (số phiên mua hàng chiếm tỷ lệ rất nhỏ), Độ chính xác tổng thể (Accuracy) sẽ bị loại bỏ khỏi tiêu chí đánh giá chính.

Thay vào đó, việc tối ưu và đánh giá hiệu năng mô hình được đặt trọng tâm tuyệt đối vào chỉ số **ROC-AUC** (Area Under the Receiver Operating Characteristic Curve). Đây là thước đo quan trọng nhất, đánh giá toàn diện khả năng phân tách và xếp hạng xác suất khách hàng mua và không mua ở mọi ngưỡng quyết định (threshold) khác nhau.

Bên cạnh sức mạnh phân loại học máy từ ROC-AUC, ở góc độ ứng dụng kinh doanh, các chỉ số **Độ phủ (Recall)** và **F1-Score** vẫn được theo dõi sát sao. Việc tinh chỉnh ngưỡng quyết định để tối ưu Recall sẽ đảm bảo doanh nghiệp không bỏ lọt các khách hàng tiềm năng có ý định mua sắm (High Intent), từ đó phục vụ trực tiếp và mang lại tỷ suất hoàn vốn (ROI) cao cho các chiến dịch Remarketing (tiếp thị lại) thời gian thực.

5.2 Xây dựng mô hình

Trước khi xây dựng mô hình ta phải xử lý một vấn đề:

Thông qua quá trình Khám phá dữ liệu (EDA), ta nhận thấy tập dữ liệu mang đặc tính mất cân bằng lớp (Class Imbalance) cực kỳ nghiêm trọng. Cụ thể, trong tổng số 4,504,473 phiên truy cập:

- Nhóm đa số (Nhãn 0 - Không mua hàng): Chiếm 96.90% với 4,364,667 mẫu.
- Nhóm thiểu số (Nhãn 1 - Có mua hàng): Chỉ chiếm 3.10% với 139,806 mẫu.

Sự chênh lệch với tỷ lệ xấp xỉ 31:1 này khiến các thuật toán học máy tiêu chuẩn có xu hướng ưu tiên hội tụ về hàm cực tiểu bằng cách dự đoán nhãn 0 cho mọi trường hợp (thiên lệch về Majority Class).

Để ép thuật toán phải "chú ý" hơn vào nhóm khách hàng mua hàng, ta áp dụng kỹ thuật gán trọng số nghịch đảo với tần suất xuất hiện của lớp đó

trong tập dữ liệu. Công thức tổng quát (được sử dụng phổ biến trong thư viện Scikit-Learn) như sau:

$$W_j = \frac{N_{total}}{k \times N_j}$$

Trong đó:

- W_j : Trọng số áp dụng cho nhãn $j \in \{0, 1\}$.
- N_{total} : Tổng số lượng mẫu trong tập dữ liệu (4,504,473).
- k : Số lượng lớp của bài toán phân loại ($k = 2$).
- N_j : Số lượng mẫu thực tế của nhãn j .

Áp dụng vào bộ dữ liệu thực tế của đề án, ta tính được bộ trọng số như sau:

- **Trọng số Nhãn 0 (W_0):** $W_0 = \frac{4,504,473}{2 \times 4,364,667} \approx \mathbf{0.516}$
- **Trọng số Nhãn 1 (W_1):** $W_1 = \frac{4,504,473}{2 \times 139,806} \approx \mathbf{16.110}$

Trọng số được tính toán sẽ được tích hợp trực tiếp vào quá trình tối ưu hóa. Xét ví dụ với mô hình sử dụng hàm mất mát **Binary Cross-Entropy (Log-Loss)**, hàm nguyên bản sẽ được điều chỉnh thành Hàm mất mát có trọng số (Weighted Binary Cross-Entropy):

$$L_{weighted} = -\frac{1}{N} \sum_{i=1}^N \left[\mathbf{W}_1 \cdot y_i \log(p_i) + \mathbf{W}_0 \cdot (1 - y_i) \log(1 - p_i) \right]$$

Phân tích ý nghĩa toán học:

- y_i là nhãn thực tế (0 hoặc 1), và p_i là xác suất dự đoán của mô hình.
- Nếu mô hình dự đoán sai một khách hàng **thực sự có mua hàng** (Nhãn 1, $y_i = 1$), mức phạt (penalty) được nhân với $W_1 = 16.110$.
- Ngược lại, nếu mô hình dự đoán sai một khách hàng **không mua hàng** (Nhãn 0, $y_i = 0$), mức phạt chỉ được nhân với $W_0 = 0.516$.

Như vậy, với thiết lập này, "chi phí"(cost) khi mô hình phân loại sai một khách hàng thuộc nhóm thiểu số sẽ bị **phạt nặng gấp khoảng 31 lần** ($\frac{16.110}{0.516}$) so với việc đoán sai nhóm đa số. Sự điều chỉnh này triệt tiêu hoàn toàn sự thiên lệch của dữ liệu, giúp mô hình tập trung tìm kiếm các ranh giới quyết định (decision boundaries) phức tạp để nhận diện người mua hàng, qua đó trực tiếp tối ưu hóa chỉ số ROC-AUC như mục tiêu đã đề ra.

Từ đây ta nhận thấy có thể xây dựng các mô hình như sau để dự đoán:

- Mô hình hồi quy logistic làm mô hình cơ sở
- Mô hình cây quyết định
- Mô hình Random Forest
- Mô hình Gradient Boosting như LightGBM, XGBoost,...

Lý do lựa chọn những mô hình này là do thời gian dự đoán nhanh vì hệ thống sẽ phải dự đoán mỗi khi người dùng có sự kiện mới như cho hàng vào giỏ, xem hàng... Và số lượng dự đoán có thể lên đến hàng trăm nghìn lần trong khoảng thời gian ngắn nếu hệ thống quá phức tạp thì sẽ không đáp ứng được dự đoán Real-time.


6 Kết quả và đánh giá

6.1 Kết quả mô hình cơ sở

Ta chọn mô hình cơ sở là mô hình **Hồi quy Logistic (Logistic Regression)**.

Ta thiết lập cho mô hình các siêu tham số sau: Trọng số nhân 0: 0,516, Trọng số nhân 1: 16,110 và số vòng lặp tối đa: 100

Sau khi huấn luyện mô hình với các siêu tham số trên ta được mô hình có chỉ số **Điểm ROC-AUC**: 0.9215 trên tập test



Hình 22: Biểu đồ ROC


Bảng 3: Báo cáo kết quả phân loại

Nhóm / Chỉ số	Precision	Recall	F1-Score	Support
0 (Không mua)	0.99	0.83	0.91	872,934
1 (Có mua)	0.14	0.85	0.24	27,961
Accuracy			0.83	900,895

6.2 Mô hình Random Forest

Ta sẽ thiết lập các siêu tham số sau đây cho mô hình: Số cây 100, Chiều sâu tối đa: 12, Trọng số nhãn 0: 0,516, Trọng số nhãn 1: 16,110

Sau khi chạy mô hình và dự đoán trên tập test ta được một mô hình có **Điểm ROC-AUC : 0.9671**



Hình 23: ROC của mô hình Random Forest

Nhận xét: Mô hình này có sự cải thiện rõ rệt so với mô hình cơ sở (ROC-AUC từ 0.921 lên 0.967). Chỉ số ROC-AUC bằng 0.967 khẳng định rằng: Nếu chọn ngẫu nhiên một khách hàng *có mua* và một khách hàng *không mua*, mô hình có tới 96.7% khả năng xếp hạng điểm xác suất (Probability Score) của khách hàng có mua cao hơn. Điều này cực kỳ lý tưởng cho bài toán Remarketing: Doanh nghiệp hoàn toàn có thể sắp xếp danh sách khách hàng theo điểm xác suất giảm dần và chỉ cần cắt lấy Top 5% – 10% người dùng đứng đầu để chạy quảng cáo, qua đó tối ưu hóa tỷ lệ chuyển đổi và tiết kiệm tối đa ngân sách marketing.

Đến với các metric khác ta sẽ chọn một ngưỡng quyết định bằng chỉ số

Youden được tính như sau:

$$J = TPR - FPR$$

Trong đó:

- Tỷ lệ Dương tính thật TPR
- Tỷ lệ Dương tính giả FPR

Ta sẽ chọn J thuộc đồ thị ROC nhưng cách xa đường ngẫu nhiên nhất từ đó thu được ngưỡng tương ứng.

Ta thu được J lớn nhất là: 0.8594

Ngưỡng tối ưu (Threshold) tương ứng là: 0.5759

Bảng 4: Báo cáo kết quả phân loại

Nhóm / Chỉ số	Precision	Recall	F1-Score	Support
0 (Không mua)	1.00	0.90	0.95	872,934
1 (Có mua)	0.24	0.96	0.38	27,961
Accuracy			0.90	900,895
Macro Avg	0.62	0.93	0.66	900,895
Weighted Avg	0.97	0.90	0.93	900,895

Nhận xét:

- **Độ nhạy (Sensitivity/Recall) đạt 0.96:** Việc tinh chỉnh ngưỡng quyết định giúp thuật toán nhận diện thành công 96% tổng số phiên truy cập có phát sinh giao dịch (27,961 mẫu). Trong cấu trúc của hệ thống khuyến nghị và tiếp thị, mức độ thu hồi này đảm bảo Tỷ lệ Âm tính giả (False Negative Rate) được duy trì ở mức tối thiểu (4%), đáp ứng trực tiếp yêu cầu tối đa hóa xác suất tiếp cận tập khách hàng mục tiêu.
- **Tỷ lệ Dương tính giả (False Positive Rate) được kiểm soát:** Từ hệ thức Youden $J = TPR - FPR$, với $TPR = 0.96$ và $J = 0.8594$, Tỷ lệ Dương tính giả được xác định ở mức xấp xỉ 0.10. Hệ số này tương đồng với kết quả độ đặc hiệu (Specificity, tức Recall của Nhãn 0) đạt 0.90. Phân tích này minh chứng mô hình có khả năng phân loại chính xác 90% các phiên truy cập không mang ý định giao dịch, qua đó hạn chế sai lệch hệ thống và giảm thiểu chi phí cơ hội do việc phân bổ sai nguồn lực.

- **Độ chuẩn xác (Precision) và Hệ số nâng (Lift Score):** Dù Precision của Nhân 1 ghi nhận ở mức 0.24, giá trị này cần được đánh giá đối sánh với tỷ lệ cơ sở (Base Rate) của tập dữ liệu phân tích, vốn chỉ ở mức 3.1% (27,961 trên tổng số 900,895 mẫu). Quá trình phân loại đã tạo ra hệ số nâng (Lift) xấp xỉ 7.74 lần ($\frac{0.24}{0.031}$). Nghĩa là, mật độ khách hàng có giao dịch trong tập kết quả dự đoán dương tính cao gấp gần 8 lần so với phân phối tự nhiên ban đầu.
- **Tính toàn vẹn của ranh giới quyết định:** Mức điểm F1-Score 0.38 (trung bình điều hòa giữa Precision và Recall) tái khẳng định năng lực của mô hình trong việc vượt qua giới hạn của hiện tượng thiên lệch đa số (Majority Class Bias). Ranh giới quyết định được thiết lập tại $t = 0.5759$ đã mang lại trạng thái cân bằng tối ưu giữa việc cực đại hóa khả năng phân mảnh lớp thiểu số và duy trì độ chính xác thống kê của hệ thống.


6.3 Mô hình sử dụng Gradient Boosting

Đối với mô hình sử dụng Gradient Boosting thì báo cáo này sẽ sử dụng LightBGM.

Các siêu tham số:

- Số lượng cây quyết định ($n_estimators = 420$)
- Tốc độ học ($learning_rate \approx 0.027$)
- Chiều sâu tối đa ($max_depth = 13$)
- Số lượng nút lá tối đa ($num_leaves = 186$)
- Số lượng mẫu tối thiểu tại một lá ($min_child_samples = 205$)
- Tỷ lệ lấy mẫu dữ liệu ($subsample \approx 0.88$)
- Tỷ lệ lấy mẫu đặc trưng ($colsample_bytree \approx 0.79$)

Sau khi chạy mô hình trên tập test ta có **điểm ROC-AUC: 0.9699** và **ngưỡng quyết định: 0.525**



Hình 24: Đồ thị ROC của LightGBM

Bảng 5: Báo cáo kết quả phân loại

Nhóm / Chỉ số	Precision	Recall	F1-Score	Support
0 (Không mua)	1.00	0.90	0.95	872,934
1 (Có mua)	0.24	0.96	0.39	27,961
Accuracy			0.91	900,895
Marco Avg	0.62	0.93	0.67	900,895
Weighted Avg	0.97	0.91	0.93	900,895

Nhận xét:

- **Năng lực nhận diện khách hàng tiềm năng (Độ thu hồi của Nhóm có giao dịch đạt 0.96):** Đây là chỉ số mang tính bứt phá của hệ thống. Trong tổng số 27,961 phiên truy cập thực sự phát sinh giao dịch, thuật toán đã khoanh vùng và nhận diện chính xác tới 96%. Điều này đảm bảo tỷ lệ âm tính giả (khách hàng bị bỏ sót) được nén xuống mức tối thiểu chỉ 4%. Đối với bài toán tiếp thị lại, việc duy trì độ thu hồi ở ngưỡng cực đại này giúp doanh nghiệp bảo toàn gần như nguyên vẹn cơ hội chuyển đổi doanh thu.
- **Hệ số nâng và hiệu quả lọc nhiễu (Độ chuẩn xác của Nhóm có giao dịch đạt 0.24):** Dù mức điểm 0.24 thoát nhìn có vẻ thấp trong các hệ quy chiếu học máy thông thường, nhưng khi đặt trong

bối cảnh dữ liệu thực tế (tỷ lệ mua hàng phân phối tự nhiên chỉ chiếm khoảng 3.1%), đây lại là minh chứng cho sức mạnh phân loại của mô hình. Hệ thống đã tạo ra hệ số nâng xấp xỉ 7.7 lần ($\frac{0.24}{0.031}$). Nghĩa là, chất lượng của tệp khách hàng do mô hình dự đoán mang lại khả năng chốt đơn cao gấp 7.7 lần so với việc tiếp cận ngẫu nhiên.

- **Khả năng tối ưu hóa chi phí vận hành (Độ thu hồi của Nhóm không giao dịch đạt 0.90):** Tương ứng với tỷ lệ dương tính thật 0.96 ở nhóm khách hàng có giao dịch, thuật toán vẫn duy trì được độ đặc hiệu ở mức 0.90. Điều này minh chứng hệ thống đã tự động sàng lọc và loại bỏ thành công 90% các phiên truy cập chỉ mang tính chất tham khảo, giúp giải phóng một lượng khổng lồ ngân sách quảng cáo lẽ ra bị lãng phí cho tập khách hàng không có ý định mua sắm.
- **Tính toàn vẹn của mô hình (Độ chính xác tổng thể 0.91 và Điểm F1 đạt 0.39):** Việc đánh đổi 9% độ chính xác tổng thể (so với mức 100% lý tưởng) là hệ quả tất yếu và được chấp nhận hoàn toàn trong lý thuyết học tập nhảy cẫng với chi phí. Điểm F1 của nhóm thiểu số đạt 0.39 xác nhận thuật toán đã thoát khỏi cạm bẫy thiên lệch nhóm đa số, hoàn thành xuất sắc mục tiêu nhận diện sự kiện hiếm trong miền dữ liệu thương mại điện tử.

6.4 Tổng hợp kết quả

Sau đây là tổng hợp Macro Avg của các mô hình:

Bảng 6: Bảng tổng hợp so sánh hiệu suất giữa các mô hình (Chọn ngưỡng tối ưu Recall)

Mô hình	ROC-AUC	Accuracy	Macro Precision	Macro Recall	Macro F1
Logistic Regression	0.9215	0.83	0.56	0.84	0.57
Random Forest	0.9671	0.90	0.62	0.93	0.66
LightGBM	0.9699	0.91	0.62	0.93	0.67

7 Khuyến nghị ra quyết định

7.1 Khuyến nghị

Dựa trên kết quả triển khai mô hình LightGBM và các phát hiện từ quá trình Khám phá dữ liệu (EDA), hệ thống không chỉ dừng lại ở việc dự đoán chính xác ý định mua hàng mà còn mở ra cơ hội tái cấu trúc toàn diện chiến lược vận hành của doanh nghiệp Thương mại điện tử. Dưới đây là 4 khuyến nghị chiến lược nhằm chuyển hóa sức mạnh của Trí tuệ nhân tạo (AI) thành Lợi nhuận ròng (Net Profit):

1. Chuyển dịch từ Marketing đại trà sang Marketing mục tiêu

- **Cơ sở dữ liệu:** Mô hình đề xuất đạt Độ phủ (Recall) 61% và Độ chuẩn xác (Precision) 27%.
- **Khuyến nghị:** Doanh nghiệp cần chấm dứt việc chạy quảng cáo bám đuôi (Retargeting Ads trên Facebook, Google) hoặc gửi Email Marketing cho toàn bộ 100% khách hàng truy cập website. Thay vào đó, ngân sách quảng cáo chỉ nên giải ngân vào danh sách khách hàng được mô hình gán nhãn 1 (**Có ý định mua**).
- **Lợi ích kinh tế:** Mặc dù Precision là 27%, tỷ lệ này đã cao hơn gấp 10 đến 15 lần so với tỷ lệ chuyển đổi tự nhiên (Organic Conversion Rate thường ở mức 2%). Điều này giúp doanh nghiệp giảm thiểu triệt để Chi phí thu hút khách hàng (CAC - Customer Acquisition Cost) và tăng vọt Lợi tức đầu tư quảng cáo (ROAS).

2. Chiến lược phân phối Khuyến mãi thông minh

- **Cơ sở dữ liệu:** Phân tích Tương quan chỉ ra mức giá (`avg_price`) không ảnh hưởng tới quyết định mua, nhưng các tương tác giỏ hàng (`total_carts`, `total_removes`) lại là tín hiệu chốt đơn cực kỳ mạnh.
- **Khuyến nghị:** Không phát mã giảm giá (Voucher) một cách mù quáng. Hệ thống CRM cần tích hợp mô hình AI để phân luồng người dùng theo Xác suất dự đoán (Probability Score):
 - **Xác suất $> 90\%$ (Chắc chắn mua):** Khách hàng đã quyết tâm mua. **Không cấp Voucher** để bảo vệ biên lợi nhuận tuyệt đối.
 - **Xác suất từ 70% – 90% (Đang phân vân):** Khách hàng có thao tác thêm và xóa khỏi giỏ nhiều lần. Hệ thống tự động kích hoạt một **Pop-up Voucher Freeship có thời hạn 15 phút**. Hiệu ứng tâm lý sợ bỏ lỡ (FOMO) sẽ ép khách hàng chốt đơn ngay lập tức thay vì thoát trang.
 - **Xác suất $< 50\%$ (Chỉ lướt dạo):** **Không cấp Voucher**, thay vào đó hiển thị giao diện gợi ý các bài viết blog làm đẹp hoặc các sản phẩm xu hướng để thu thập Email (Lead Generation).

3. Can thiệp Chăm sóc khách hàng theo Thời gian thực

- **Khuyến nghị:** Tích hợp mô hình trực tiếp vào hệ thống Backend (sử dụng công nghệ truyền phát dữ liệu thời gian thực như Apache Kafka).
- **Quy trình hành động:** Khi hệ thống ghi nhận một phiên truy cập có Thời lượng (`session_duration`) lớn hơn mức trung bình và Xác suất chốt đơn cao, nhưng khách hàng lại dừng lại quá 3 phút ở trang Thanh toán

(Checkout), hệ thống sẽ gửi cảnh báo đến bộ phận Chăm sóc khách hàng (CSKH). Nhân viên CSKH sẽ chủ động nhắn tin qua Live-chat: "*Chào bạn, hệ thống ghi nhận bạn đang gặp khó khăn khi thanh toán, mình có thể hỗ trợ bạn không?*". Sự can thiệp đúng lúc này là "chìa khóa vàng" để cứu vãn các giỏ hàng có giá trị cao bị bỏ rơi do lỗi kỹ thuật hoặc thiếu thông tin.

4. Tối ưu hóa Trải nghiệm Người dùng

- **Cơ sở dữ liệu:** Thuật toán phân định rõ nhóm "Bounce" (Vào xem đúng 1 sản phẩm rồi thoát) và nhóm "Active Shopping" (Xem nhiều, tương tác nhiều).
- **Khuyến nghị:** Giao diện website/ứng dụng cần được cá nhân hóa tự động. Đối với nhóm được dự đoán **Nhân 0**, giao diện nên hiển thị dạng "Khám phá" (Discovery Mode) với nhiều hình ảnh bắt mắt để giữ chân họ trên nền tảng. Ngược lại, với nhóm được dự đoán **Nhân 1**, giao diện cần tự động ẩn đi các banner quảng cáo rườm rà, đẩy nút "**Thanh toán ngay**" lên vị trí trung tâm màn hình, rút gọn tối đa số lần nhấp chuột (Click) để quá trình chốt đơn diễn ra mượt mà nhất.

7.2 Đánh giá Rủi ro và Hạn chế của hệ thống

Mặc dù mô hình LightGBM mang lại những định hướng kinh doanh rõ nét, việc áp dụng trí tuệ nhân tạo vào môi trường Thương mại điện tử thực tế luôn đi kèm với những rủi ro và giới hạn nhất định. Nhằm đảm bảo tính an toàn trong vận hành, doanh nghiệp cần lưu ý các vấn đề sau trước khi triển khai (Deployment):

1. Hạn chế về mặt Dữ liệu và Mô hình

- **Giới hạn của dữ liệu theo Phiên :** Mô hình hiện tại phân tích hành vi dựa trên từng `user_session` độc lập. Trong thực tế, chu kỳ mua sắm của khách hàng (Customer Journey) có thể kéo dài qua nhiều phiên hoặc vắt chéo qua nhiều thiết bị (Cross-device tracking) — ví dụ: khách hàng xem sản phẩm trên điện thoại nhưng thanh toán trên máy tính. Việc mô hình chưa liên kết được các chuỗi phiên này có thể làm giảm khả năng nhận diện ý định mua sắm dài hạn.
- **Hiện tượng trôi dạt khái niệm :** Dữ liệu huấn luyện được thu thập trong khoảng thời gian cụ thể (Tháng 10 - Tháng 2). Thói quen mua sắm của người tiêu dùng có tính mùa vụ (Seasonality) rất cao (ví dụ: hành vi mua sắm dịp Black Friday sẽ rất khác so với mùa hè). Nếu không thiết lập cơ chế tự động huấn luyện lại (Retraining Pipeline) định kỳ, hiệu năng của mô hình sẽ bị suy giảm theo thời gian do dữ liệu lỗi thời.

2. Rủi ro trong Triển khai Kinh doanh

- **Rủi ro thất thoát tài chính từ tỷ lệ Dương tính giả:** Mặc dù mô hình đạt Độ thu hồi (Recall) cực kỳ xuất sắc lên đến 96%, nhưng Độ chuẩn xác (Precision) ghi nhận ở mức 24%. Điều này đồng nghĩa với việc: Cứ 100 phiên truy cập được dự đoán "có khả năng mua hàng", sẽ có 76 phiên thực chất không phát sinh giao dịch. Nếu doanh nghiệp sử dụng trực tiếp danh sách dự đoán này cho các chiến dịch có **Chi phí biên cao (High Marginal Cost)** — ví dụ như gọi điện Telesales trực tiếp hoặc phát hành Voucher mệnh giá lớn — sự nhận diện nhầm lẫn của thuật toán sẽ gây lãng phí ngân sách nghiêm trọng. Do đó, cấu hình mô hình hiện tại chỉ an toàn và tối ưu đối với các chiến dịch tiếp thị có chi phí tiếp cận thấp (như Retargeting Ads, Email Marketing, hoặc Push Notification).
- **Rủi ro thao túng thuật toán:** Nếu chính sách ưu đãi được tự động hóa hoàn toàn dựa trên xác suất dự đoán của mô hình, một bộ phận người dùng có thể nhận diện được quy luật hoạt động. Họ có khả năng chủ động tạo ra các hành vi giả lập (như liên tục thao tác thêm/xóa giỏ hàng hoặc cố tình kéo dài thời lượng phiên) nhằm thao túng hệ thống phát hành mã giảm giá. Để phòng ngừa, kiến trúc hệ thống thực tế cần tích hợp thêm *Cơ chế giới hạn tần suất (Rate Limiting)* và *Yếu tố phân phối ngẫu nhiên (Randomization)* trên mỗi định danh khách hàng (`user_id`).
- **Rủi ro gián đoạn trải nghiệm người dùng:** Việc ứng dụng kết quả dự đoán để can thiệp thời gian thực (Real-time Intervention) — chẳng hạn như hiển thị khung quảng cáo động (Pop-up) hoặc trợ lý ảo (Live-chat) — nếu diễn ra với tần suất thiếu kiểm soát sẽ gây phản tác dụng. Sự can thiệp thái quá từ hệ thống có thể làm đứt gãy luồng mua sắm tự nhiên, khiến khách hàng cảm thấy bị làm phiền hoặc phát sinh tâm lý e ngại về việc dữ liệu hành vi cá nhân bị theo dõi quá mức (Privacy Concerns).

Giải pháp khắc phục chung: Trước khi triển khai toàn hệ thống, doanh nghiệp bắt buộc phải thực hiện **Kiểm thử A/B (A/B Testing)** trên một tệp khách hàng nhỏ (ví dụ 10% lưu lượng truy cập). Chỉ khi kết quả A/B Testing chứng minh được Lợi nhuận ròng (Net Profit) của nhóm dùng AI cao hơn có ý nghĩa thống kê so với nhóm đối chứng (Control Group), mô hình mới được phép triển khai diện rộng (Mass Rollout).

8 Hạn chế và hướng phát triển

8.1 Hạn chế của dữ liệu và mô hình hiện tại

Mặc dù kiến trúc LightGBM đã mang lại những cải thiện đáng kể về năng lực dự báo, nghiên cứu vẫn tồn tại một số giới hạn nhất định về mặt khai thác dữ liệu và bản chất thuật toán:

- **Giới hạn phạm vi phiên truy cập đơn lẻ :** Quá trình trích xuất đặc trưng (Feature Engineering) hiện tại đang gom nhóm (Groupby) dữ liệu theo từng `user_session` độc lập. Tuy nhiên, hành vi mua sắm thực tế thường là một hành trình kéo dài (Customer Journey). Một khách hàng có thể lướt xem sản phẩm trên điện thoại vào buổi sáng (Phiên 1), sau đó đăng nhập trên máy tính để thanh toán vào buổi tối (Phiên 2). Việc mô hình đánh giá rời rạc từng phiên đã vô tình làm mất đi sự liên kết thông tin lịch sử của cùng một `user_id`.
- **Bỏ qua tính tuần tự của chuỗi hành vi :** Các đặc trưng được tổng hợp như `total_views`, `total_carts` chỉ mang tính chất thống kê số đếm (Aggregated Counts) mà không phản ánh được *thứ tự* xảy ra của các sự kiện. Về mặt logic, một phiên truy cập có thứ tự hành vi: `View` $\rightarrow$ `View` $\rightarrow$ `Cart` sẽ có xác suất chốt đơn cao hơn rất nhiều so với chuỗi `Cart` $\rightarrow$ `View` $\rightarrow$ `Remove`. Mô hình dữ liệu dạng bảng (Tabular Models) như LightGBM chưa có khả năng học được luồng thời gian (Time-series) vì mô này.

8.2 Hướng phát triển trong tương lai

Từ những hạn chế nêu trên, nghiên cứu đề xuất các hướng mở rộng và nâng cấp hệ thống trong tương lai nhằm đưa mô hình tiệm cận với mức độ hoàn hảo của các hệ thống AI công nghiệp:

- **Ứng dụng Học Sâu cho chuỗi thời gian (Deep Learning for Sequential Data):** Thay vì sử dụng phương pháp gom nhóm và tạo đặc trưng trong thống kê truyền thống, hướng phát triển là chuyển đổi bài toán sang dạng Dự đoán chuỗi . Các mạng nơ-ron hồi quy như **RNN**, **LSTM (Long Short-Term Memory)** hoặc kiến trúc **Transformer (Self-Attention Models)** sẽ được áp dụng để đưa trực tiếp chuỗi click chuột theo thứ tự thời gian vào huấn luyện. Kỹ thuật này giúp mô hình "hiểu" được ngữ cảnh của từng thao tác lướt web trước khi khách hàng ra quyết định.
- **Xây dựng quy trình MLOps và Real-time Streaming:** Phát triển hệ thống từ mức độ nghiên cứu (Jupyter Notebook) lên mức độ vận hành (Production). Sử dụng các công nghệ xử lý luồng dữ liệu thời gian thực như **Apache Kafka** hoặc **Apache Spark Streaming** để hứng dữ liệu Clickstream trực tiếp từ Website. Đồng thời, thiết lập đường ống **Continuous Training (Huấn luyện liên tục)** để mô hình tự động cập nhật trọng số hàng tuần, chống lại hiện tượng trôi dạt dữ liệu (Data Drift) do sự thay đổi theo mùa vụ của ngành Mỹ phẩm.

9 Phân công công việc

Bảng 7: Bảng phân công công việc của các thành viên trong nhóm

Thành viên	Công việc chính	Tỷ lệ đóng góp	Minh chứng
Hoàng Mạnh Đức 20237311	Tìm hiểu bài toán, mô tả dữ liệu, viết báo cáo, xây dựng mô hình,...	100%	Notebook, mô hình lưu dưới dạng .pkl, báo cáo đăng ở Github.

10 Sử dụng AI

Công cụ AI sử dụng: Gemini

Mục đích sử dụng:

- Tối ưu code
- Tìm hiểu kiến thức về các loại mô hình, ưu nhược điểm
- Tìm hiểu nghiệp vụ
- Kiểm tra chính tả, chỉnh sửa câu cú
- Hỗ trợ gõ bảng Latex

11 Minh chứng

https://github.com/hoangmanhduc1905/DSS_2025.2-169316—MI4216—Nhom—19