

Mô hình phân lớp hành vi mua hàng của khách
trên nền tảng Thương mại điện tử
Báo cáo môn học: Hệ hỗ trợ quyết định (MI4216)

Sinh viên thực hiện: Hoàng Mạnh Đức
MSSV: 20237311
Lớp: 169316

Trường Đại học Bách Khoa Hà Nội
Khoa Toán - Tin

Tháng 04 năm 2026

Nội dung báo cáo

1. Giới thiệu bài toán
2. Mục tiêu hỗ trợ ra quyết định
3. Mô tả và Tiền xử lý dữ liệu
4. Khám phá dữ liệu (EDA)
5. Huấn luyện mô hình
6. Kết quả và đánh giá
7. Khuyến nghị và Hướng phát triển

1.1 Bối cảnh ngành Thương mại điện tử

- **Sự bùng nổ:** TMĐT đang thay đổi hoàn toàn thói quen mua sắm của người tiêu dùng.
- **Nghịch lý kinh doanh:** Lượng truy cập (Traffic) nền tảng rất cao, nhưng tỷ lệ chuyển đổi (Conversion Rate) lại thấp.
- **Thực trạng:** Tỷ lệ "bỏ rơi giỏ hàng" (Cart Abandonment Rate) trung bình lên tới gần 70%.
- **Cơ hội:** Hệ thống lưu trữ dữ liệu khổng lồ dưới dạng Nhật ký sự kiện (Event Logs). Đây là cơ sở dữ liệu quan trọng để ứng dụng Học máy nhằm "đọc vị" ý định của người dùng thời gian thực.

1.2 Lý do chọn đề tài & Đối tượng sử dụng

Lý do chọn đề tài:

- **Về mặt kinh doanh:** Khắc phục lãng phí do Marketing đại trà, chuyển hướng sang Marketing cá nhân hóa (Targeted Marketing).
- **Về mặt kỹ thuật:** Giải quyết bài toán khó trong việc khai thác dữ liệu sự kiện thô, trích xuất đặc trưng và ngăn chặn rò rỉ dữ liệu.

Hệ thống phục vụ 3 phòng ban cốt lõi:

- ① **Bộ phận Marketing:** Tối ưu ngân sách quảng cáo & cấp phát Voucher.
- ② **Bộ phận CSKH:** Can thiệp thời gian thực (Live-chat).
- ③ **Bộ phận UI/UX:** Tùy biến giao diện (Dynamic UI) theo ý định mua.

2.1 Quyết định phân bổ ngân sách khuyến mãi

Bài toán: Có nên cấp phát mã giảm giá (Voucher) cho khách hàng trong phiên hiện tại không? Mức giảm là bao nhiêu?

Giải pháp từ mô hình AI: Thay vì "rải" mã giảm giá đại trà, hệ thống chia khách hàng làm 3 nhóm:

- **Chắc chắn mua (Xác suất $> 80\%$):** Khách đã có ý định rõ ràng. → *Không tặng Voucher* để bảo vệ biên lợi nhuận.
- **Đang phân vân (Xác suất $40\% - 80\%$):** Khách thêm đồ vào giỏ nhưng chần chừ. → *Tặng Pop-up Voucher 10 phút* để ép hiệu ứng FOMO.
- **Không có ý định (Xác suất $< 40\%$):** Chỉ lướt xem giá. → *Không tặng Voucher* để tránh lãng phí.

2.2 Quyết định quảng cáo bám đuôi & Can thiệp CSKH

Tối ưu Quảng cáo Retargeting:

- Chạy quảng cáo cho 100% người thoát trang là "đốt tiền".
- **Quyết định:** Chỉ lọc Top 20% khách hàng có xác suất mua cao nhất đẩy lên Facebook/Google.
- → Tiết kiệm CAC, tăng vọt ROAS.

Can thiệp thời gian thực (CSKH):

- Khách có xác suất chốt đơn cao nhưng dừng ở trang thanh toán quá 3 phút?
- **Quyết định:** Hệ thống báo động để nhân viên chủ động Live-chat: "*Chào bạn, bạn có cần hỗ trợ phí vận chuyển không?*"

3.1 Nguồn dữ liệu & Từ điển dữ liệu thô

Nguồn: eCommerce Events History in Cosmetics Shop (Kaggle).

Quy mô: > 20 triệu bản ghi nhật ký sự kiện lướt web.

Tên biến	Kiểu dữ liệu	Ý nghĩa
event_time	String	Thời điểm xảy ra sự kiện (UTC).
event_type	String	Loại tương tác: view, cart, remove_from_cart, purchase.
product_id	int64	Mã định danh sản phẩm.
category_id/code	int64 / string	Mã danh mục & Chuỗi phân cấp.
brand	string	Tên thương hiệu.
price	Float64	Giá sản phẩm (USD).
user_session	string	Mã phiên truy cập.

3.2 Kiểm tra chất lượng dữ liệu: Kiểu dữ liệu & Null

- **Kiểu dữ liệu:** Cột event_time bị nhận diện là String, cần đổi sang Datetime.
- **Dữ liệu thiếu:** brand khuyết 42%, category_code khuyết 98%.

```
1 import pandas as pd
2
3 raw_data=pd.read_csv('Data/2019-Dec.csv')
4 raw_data.info()

✓ 12.0s

<class 'pandas.DataFrame'>
RangeIndex: 3533286 entries, 0 to 3533285
Data columns (total 9 columns):
#   Column      Dtype
---  -
0   event_time   str
1   event_type   str
2   product_id   int64
3   category_id  int64
4   category_code str
5   brand        str
6   price        float64
7   user_id      int64
8   user_session str
```

```
1 raw_data.isna().sum()/3533285*100

[5] ✓ 0.1s

... event_time      0.000000
    event_type      0.000000
    product_id      0.000000
    category_id      0.000000
    category_code    98.345336
    brand           42.744613
    price           0.000000
    user_id         0.000000
    user_session     0.022047
    dtype: float64
```


3.3 Kiểm tra chất lượng dữ liệu: Trùng lặp & Ngoại lệ

- **Trùng lặp:** Phát hiện 5.2% dữ liệu trùng lặp hoàn toàn do lỗi double-click.
- **Ngoại lệ (Outliers):** Cột price chứa giá trị âm do lỗi hệ thống, hoặc giá cực cao bất thường.

```
1 print(raw_data.duplicated().sum())  
[7] ✓ 5.7s Python  
... 183860  
  
1 183860/3533285*100  
[8] ✓ 0.0s Python  
... 5.20365608774837
```

```
1 raw_data.describe()  
[9] ✓ 0.8s  
...  
      product_id  category_id  price  user_id  
count  3.533286e+06  3.533286e+06  3.533286e+06  3.533286e+06  
mean    5.473054e+06  1.555023e+18  8.871856e+00  5.223318e+08  
std     1.331331e+06  1.689262e+17  1.986474e+01  8.494819e+07  
min     3.752000e+03  1.487580e+18 -7.937000e+01  1.180452e+06  
25%    5.726191e+06  1.487580e+18  2.060000e+00  4.866830e+08
```

3.4 Làm sạch dữ liệu (Data Cleaning)

Các bước xử lý:

- Loại bỏ hoàn toàn dòng trùng lặp.
- Xóa các dòng có $\text{price} \leq 0$.
- Giới hạn ngoại lệ giá (Winsorization) ở phân vị 99th.
- Điền giá trị Null của brand bằng "Unknown".
- Xóa cột category_code.
- Xóa các user_session rác bị Null.

```
1 data = raw_data.drop_duplicates()
2 data=data[data['price']>=0]
```

[13] ✓ 9.9s

Python

Xử lý ngoại lệ

```
1 giới_hạn_99 = data['price'].quantile(0.99)
2 print(f"Giá trị bách phân vị 99: {giới_hạn_99}")
3
4 data['price'] = data['price'].clip(upper=giới_hạn_99)
5
6 data.describe()
```

[12] ✓ 0.8s

Python

... Giá trị bách phân vị 99: 103.17

...

	product_id	category_id	price	user_id
count	3.349409e+06	3.349409e+06	3.349409e+06	3.349409e+06
mean	5.470482e+06	1.555165e+18	8.475992e+00	5.228340e+08
std	1.336454e+06	1.690827e+17	1.519136e+01	8.527801e+07
min	3.752000e+03	1.487580e+18	0.000000e+00	1.180452e+06
25%	5.726184e+06	1.487580e+18	2.060000e+00	4.875069e+08

3.5 Trích xuất đặc trưng (Feature Engineering)

- **Biến mục tiêu:** $Y = 1$ nếu phiên có giao dịch mua (purchase), ngược lại $Y = 0$. (*Lưu ý: Xóa toàn bộ event mua khỏi tập train để chống Leakage*).
- **Đặc trưng Lịch sử KH (RFM):**
 - **R:** Số ngày kể từ lần mua cuối.
 - **F:** Tổng số phiên mua hàng trong quá khứ.
 - **M:** Tổng tiền đã chi tiêu. (Tất cả quy về thang điểm 1-4).
- **Đặc trưng Phiên:** total_views, total_carts, total_removes, session_duration, unique_products, avg_price...

3.5 Trích xuất đặc trưng (Feature Engineering)


Bảng 1: 5 dòng dữ liệu sau trích xuất

user_session	day	hr	views	carts	rmvs	dur(s)	avg_p	max_p	1_brd
bfb1...105f	7	15	1	0	0	0	14.29	14.29	1
7a79...b958	7	9	1	0	0	0	7.14	7.14	1
50fb...8508	3	21	6	2	0	1292	5.49	15.48	0
6582...8711	6	15	1	0	0	0	13.13	13.13	1
16e6...5e78	5	9	7	0	0	545	3.73	18.89	0

user_session	u_prd	u_brd	R	F	M	RFM	enc_brd	is_purchased
bfb1...105f	1	1	0	0	0	0	0.039	0
7a79...b958	1	1	0	0	0	0	0.029	0
50fb...8508	6	2	2	3	2	7	0.039	0
6582...8711	1	1	0	0	0	0	0.035	0
16e6...5e78	7	3	0	0	0	0	0.039	0


4.1 EDA: Phân bố nhãn mục tiêu (Class Imbalance)

- Dữ liệu mất cân bằng nhãn cực kỳ nghiêm trọng.
- **Nhãn 0 (Không mua): 96.90%**
- **Nhãn 1 (Có mua): 3.10%**
- **Hệ quả:** Thuật toán sẽ có xu hướng đoán toàn bộ là 0. Cần sử dụng thuật toán gán trọng số lớp (Class Weights) ở bước huấn luyện.




4.2 EDA: Phân bố hành vi trong phiên truy cập


Mật độ phân bố của đặc trưng: total_views theo Nhân




Mật độ phân bố của đặc trưng: session_duration theo Nhân



Mật độ phân bố của đặc trưng: total_carts theo Nhân







Mật độ phân bố của đặc trưng: total_removes theo Nhân



4.3 EDA: Insight từ Hành vi truy cập

- **Nhóm "Bounce"(Thoát trang nhanh):** Tập trung ở mức 1 view, 0 giây. Đây là nhóm khách hàng "click dạo" hoặc vào nhầm link.
- **"Thêm giỏ"& "Xóa khỏi giỏ" đều tích cực:** Nhóm chốt đơn (Lớp 1) có tỷ lệ `total_removes` trải dài. Việc xóa khỏi giỏ phản ánh sự cân nhắc, so sánh kỹ lưỡng (Active Shopping) chứ không phải tín hiệu xấu.
- **Quy trình so sánh:** Khách hiếm khi mua ngay món đầu tiên. Họ xem từ 2 đến 6 `unique_products` trước khi chốt đơn.

4.4 EDA: So sánh Lịch sử khách hàng (RFM)





4.5 EDA: Insight từ Đặc trưng RFM

- **Phân hóa dữ liệu rõ rệt:** Tồn tại sự chênh lệch khổng lồ giữa hai nhóm. Nhãn 1 (Có mua) có tổng điểm RFM trung bình đạt 7.15, cao gấp 3.3 lần Nhãn 0.
- **Sức mạnh dự báo (Predictive Power):** Các chỉ số R, F, M độc lập đều cho thấy nhóm Nhãn 1 áp đảo. Đây sẽ là nhóm đặc trưng đóng góp trọng số lớn nhất cho mô hình Học máy.
- **Bản chất kinh doanh:** Tỷ lệ chuyển đổi phụ thuộc lớn vào lòng trung thành. Khách chi tiêu cao (M lớn), mua thường xuyên (F lớn), tương tác gần đây (R lớn) rất dễ chốt đơn tiếp.

4.6 EDA: Yếu tố Thời gian

Phân tích Chu kỳ thời gian:


- Xác suất mua hàng đạt đỉnh vào khung giờ sáng (**9:00 - 11:00**).
- Chạm đáy vào khung giờ rạng sáng.
- Đặc trưng day_of_week (ngày trong tuần) ít biến động → Biến dự báo yếu (Weak Predictor).



4.7 EDA: Ma trận Tương quan (Correlation)

Nhận xét từ Ma trận:

- **Đa cộng tuyến mạnh:** Nhóm định giá (avg, max) tương quan 0.92.
- **Mức giá không quan trọng:** Tương quan giữa giá và nhãn xấp xỉ 0. Nghĩa là giá cao hay thấp không quyết định việc khách chốt đơn.
- **Đặc tính phi tuyến:** Các biến chỉ tương quan yếu với nhãn. Bắt buộc phải dùng mô hình Cây (Tree-based) thay vì Tuyến tính.



5.1 Chiến lược Đánh giá & Xử lý Mất cân bằng

Mục tiêu Đánh giá:

- Bỏ qua Accuracy. Tối ưu tuyệt đối vào chỉ số **ROC-AUC**.
- Theo dõi sát **Recall** để đảm bảo không bỏ lọt khách hàng.

Cấu hình Trọng số chống thiên lệch (Class Weights):

Ép thuật toán "chú ý" vào nhóm chốt đơn thông qua công thức:

$$W_j = \frac{N_{total}}{k \times N_j}$$

- **Trọng số Nhãn 0 (W_0):** 0.516
- **Trọng số Nhãn 1 (W_1):** 16.110
- *Phạt nặng gấp 31 lần nếu đoán sai khách hàng có mua hàng!*


6.1 Kết quả Mô hình cơ sở (Logistic Regression)

Thiết lập Hồi quy Logistic:

- Trọng số $W_0 = 0.516$, $W_1 = 16.110$.
- Số vòng lặp tối đa: 100.

Kết quả:

- **Điểm ROC-AUC:** 0.9215.
- Đường cong ROC thể hiện khả năng phân tách cơ bản nhưng chưa thực sự tối ưu do giới hạn tuyến tính.



6.2 Kết quả Mô hình

Bảng 2: Báo cáo kết quả phân loại

Nhóm / Chỉ số	Precision	Recall	F1-Score	Support
0 (Không mua)	0.99	0.83	0.91	872,934
1 (Có mua)	0.14	0.85	0.24	27,961
Accuracy			0.83	900,895


6.2 Kết quả Mô hình Random Forest

Thiết lập Random Forest:

- 100 cây, Sâu tối đa 12.
- Có áp dụng Class Weights.
- Ngưỡng Youden tối ưu: 0.5759.

Kết quả:

- **ROC-AUC bứt phá lên 0.9671.**
- Khả năng xếp hạng xác suất cực kỳ lý tưởng cho bài toán Remarketing.



6.3 Đánh giá chi tiết Random Forest

Bảng 3: Báo cáo kết quả phân loại (Random Forest)

Nhóm / Chỉ số	Precision	Recall	F1-Score	Support
0 (Không mua)	1.00	0.90	0.95	872,934
1 (Có mua)	0.24	0.96	0.38	27,961
Accuracy			0.90	900,895

Nhận xét sâu:

- **Độ nhạy (Recall) 0.96:** Nhận diện trúng 96% tổng số phiên có giao dịch. Không bỏ lọt cơ hội kinh doanh.
- **Lift Score:** Precision 0.24 nghe có vẻ thấp, nhưng so với mức tự nhiên (3.1%) thì hệ thống đã **Nâng chất lượng tệp khách lên 7.74 lần**.


6.4 Kết quả Mô hình Gradient Boosting (LightGBM)

Thiết lập siêu tham số (LightGBM):

- Số lượng cây: 420 | Tốc độ học: 0.027
- Sâu tối đa: 13 | Nút lá tối đa: 186
- Mẫu tối thiểu tại lá: 205
- Lấy mẫu dữ liệu: 0.88 | Đặc trưng: 0.79

Kết quả:

- Điểm ROC-AUC: 0.9699
- Ngưỡng quyết định tối ưu: 0.525



6.5 Kết quả Mô hình Gradient Boosting (LightGBM)

Bảng 4: Báo cáo kết quả phân loại (LightGBM)

Nhóm / Chỉ số	Precision	Recall	F1-Score	Support
0 (Không mua)	1.00	0.90	0.95	872,934
1 (Có mua)	0.24	0.96	0.39	27,961
Accuracy			0.91	900,895

Nhận xét tổng thể LightGBM (ROC-AUC: 0.9699):

- Thu hồi 96% khách có giao dịch → Bảo toàn doanh thu.
- Đặc hiệu 90% (Recall lớp 0) → Tự động loại bỏ 90% khách "lướt dạo", tiết kiệm khổng lồ ngân sách quảng cáo.
- Vượt qua hoàn toàn cạm bẫy thiên lệch đa số của bài toán.

6.6 Tổng hợp và So sánh Hiệu suất các Mô hình

Bảng 5: Bảng tổng hợp các chỉ số đánh giá trên tập Kiểm thử (Tập trung vào Nhãn 1: Có mua hàng)

Mô hình	ROC-AUC	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.9215	0.83	0.14	0.85	0.24
Random Forest	0.9671	0.90	0.24	0.96	0.38
LightGBM	0.9699	0.91	0.24	0.96	0.39

7.1 Khuyến nghị Ra quyết định (Marketing & Khuyến mãi)

1. Chuyển dịch sang Marketing mục tiêu:

- Ngừng chạy Ads bám đuôi đại trà.
- Tập trung ngân sách vào tệp được AI gán **Nhãn 1**.
- *Hiệu quả*: Giảm mạnh CAC, tăng ROAS gấp nhiều lần do tệp khách hàng được tinh lọc.

2. Phân phối Khuyến mãi Thông minh:

- Khách chắc chắn mua (Xác suất $> 90\%$): **Không cấp mã**.
- Khách phân vân (Xác suất 70 – 90%): **Bật Pop-up Voucher 15 phút**.
- Khách lướt dạo (Xác suất $< 50\%$): **Gợi ý đọc Blog** để lấy Email.

7.2 Khuyến nghị Ra quyết định (CSKH & Giao diện)

3. Can thiệp Chăm sóc Khách hàng Thời gian thực:

- Tích hợp mô hình vào Backend qua Apache Kafka.
- Nếu AI phát hiện phiên có *Xác suất cao + Dừng quá lâu ở Checkout*.
- → Báo động cho CSKH vào Live-chat can thiệp ngay để cứu đơn hàng.

4. Tối ưu Trải nghiệm (Dynamic UI/UX):

- **Nhóm 0:** Giao diện Discovery (Khám phá) nhiều hình ảnh.
- **Nhóm 1:** Giao diện Checkout. Ẩn quảng cáo rườm rà, đẩy nút **Thanh toán** ra giữa màn hình.

7.3 Đánh giá Rủi ro và Hạn chế

Rủi ro Triển khai Kinh doanh:

- **Thất thoát do False Positives:** Precision 24% nghĩa là trong 100 người dự đoán mua, có 76 người không mua. **Tuyệt đối không** dùng mô hình này để tặng Voucher tiền mặt lớn hay gọi điện Telesales. Chỉ hợp với Email/Push Notification.
- **Thao túng AI:** Khách hàng có thể cố tình giả vờ để ép AI nhả mã giảm giá. Cần giới hạn Rate Limiting.
- **Bắt buộc:** Phải chạy **A/B Testing** trước khi đưa ra toàn hệ thống.

Hạn chế của Kỹ thuật hiện tại:

- Chỉ dự đoán trong 1 phiên duy nhất, chưa nổi được chuỗi hành trình vắt chéo thiết bị (Cross-device).
- Dữ liệu dạng đếm (count), đánh mất tính tuần tự (Time-series) của click.

7.4 Hướng phát triển trong tương lai

Định hướng nâng cấp Hệ thống AI:

- **Ứng dụng Học Sâu (Deep Learning):** Chuyển sang mô hình Dữ liệu chuỗi. Sử dụng **RNN, LSTM** hoặc **Transformer** để AI "hiểu" được tuần tự click chuột (Ví dụ: View → Cart sẽ khác với Cart → Remove).
- **Hệ thống MLOps:**
 - Hứng dữ liệu Clickstream theo thời gian thực (Spark Streaming).
 - Huấn luyện liên tục (Continuous Training) để chống hiện tượng trôi dạt dữ liệu (Data Drift) do mùa vụ.