

Mô hình phân lớp hành vi mua hàng của khách trên nền tảng Thương mại điện tử

Báo cáo Đồ án Học máy

Sinh viên thực hiện: Hoàng Mạnh Đức
MSSV: 20237311

Trường Đại học Bách Khoa Hà Nội

Ngày 17 tháng 6 năm 2026

Nội dung trình bày

1. Giới thiệu bài toán
2. Mô tả và Tiền xử lý dữ liệu
3. Khám phá dữ liệu (EDA)
4. Huấn luyện mô hình
5. Kết quả và Đánh giá
6. Khuyến nghị và Hướng phát triển

1.1 Bối cảnh & Lý do chọn đề tài

Bối cảnh ngành TMĐT:

- Lượng truy cập (Traffic) cực cao nhưng tỷ lệ chuyển đổi (Conversion Rate) rất thấp.
- Tỷ lệ "bỏ rơi giỏ hàng" (Cart Abandonment Rate) trung bình lên tới gần **70%**.
- Dữ liệu Nhật ký sự kiện (Event Logs) khổng lồ là mỏ vàng để Học máy "đọc vị" người dùng.

Lý do chọn đề tài:

- **Về mặt kinh doanh:** Khắc phục lãng phí do Marketing đại trà, chuyển sang Marketing cá nhân hóa (Targeted Marketing), tối ưu biên lợi nhuận.
- **Về mặt kỹ thuật:** Khai thác dữ liệu sự kiện thô (Raw Event Logs), giải quyết thách thức trích xuất đặc trưng (Feature Engineering) và kiểm soát rò rỉ dữ liệu (Data Leakage).

1.2 Đối tượng sử dụng & Hỗ trợ ra quyết định

Mô hình phục vụ 3 phòng ban cốt lõi:

- ➊ **Bộ phận Marketing:** Tối ưu hóa ngân sách quảng cáo bám đuôi (Retargeting) và cấp phát Voucher thông minh (Smart Vouchering).
- ➋ **Bộ phận CSKH:** Can thiệp thời gian thực (Real-time Intervention) bằng Pop-up Live Chat khi khách hàng dừng lâu ở trang thanh toán.
- ➌ **Bộ phận UI/UX:** Tùy biến giao diện (Dynamic UI), tinh gọn nút thanh toán cho khách hàng có ý định mua cao.

2.1 Nguồn dữ liệu & Từ điển dữ liệu

Nguồn: eCommerce Events History in Cosmetics Shop (Kaggle). Quy mô > 20 triệu bản ghi.

Bảng: Từ điển dữ liệu nguyên bản (Raw Event Logs)

Tên biến	Kiểu dữ liệu	Ý nghĩa
event_time	String	Thời điểm xảy ra sự kiện (UTC).
event_type	String	Loại tương tác: view, cart, remove_from_cart, purchase.
product_id	int64	Mã định danh sản phẩm.
category_id / category_code	int64 / string	Định danh danh mục & Tên chuỗi phân cấp.
brand	string	Thương hiệu sản phẩm.
price	Float64	Giá sản phẩm (USD).
user_id / user_session	int64 / string	Mã khách hàng & Mã phiên truy cập.

2.2 Kiểm tra chất lượng dữ liệu thô (Phần 1)

1. Kiểm tra Kiểu dữ liệu (Data Types):

- Cột event_time ban đầu được hệ thống đọc dưới dạng chuỗi văn bản (Object).
- *Vấn đề:* Cần chuyển đổi sang định dạng Datetime để phục vụ tính toán thời lượng lướt web.

```
1 import pandas as pd
2
3 raw_data=pd.read_csv('data/2019-Dec.csv')
4 raw_data.info()
5
✓ 12.0s Python

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 353285 entries, 0 to 353285
Data columns (total 9 columns):
#   column      dtype
---  ---
0  event_time  str
1  event_type  str
2  product_id  int64
3  category_id int64
4  category_code str
5  brand       str
6  price       float64
7  user_id     int64
8  user_session str
```

2. Kiểm tra Dữ liệu thiếu (Missing Values):

- Các trường giao dịch (session, type, price) đầy 100%.
- brand khuyết ~42% (phản ánh thực tế nhiều hàng giá rẻ không thương hiệu).
- category_code khuyết >98%.

```
1 raw_data.isna().sum()/353285*100
[5] ✓ 0.1s Python

...
event_time      0.000000
event_type      0.000000
product_id      0.000000
category_id     0.000000
category_code   98.345336
brand           42.744613
price           0.000000
user_id         0.000000
user_session    0.022047
dtype: float64
```

2.2 Kiểm tra chất lượng dữ liệu thô (Phần 2)

3. Kiểm tra Trùng lặp (Duplication):

- Hệ thống ghi nhận **5.2%** các dòng bị trùng lặp hoàn toàn đến từng mili-giây.
- *Nguyên nhân:* Việc người dùng click đúp (double-click) do lỗi mạng hoặc độ trễ giao diện.

```
[7] 1 print(raw_data.duplicated().sum())
    ✓ 5.7s Python
... 183860

[8] 1 183860/3533285*100
    ✓ 0.0s Python
... 5.20365608774837
```

4. Kiểm tra Ngoại lệ (Outliers):

- Cột price có xuất hiện các giá trị âm (< 0) do lỗi hệ thống backend.
- Xuất hiện một số sản phẩm có giá cao bất thường (lên tới hàng ngàn USD) gây nhiễu cho mô hình.

```
1 raw_data.describe()
```

	product_id	category_id	price	user_id
count	3.533286e+06	3.533286e+06	3.533286e+06	3.533286e+06
mean	5.473054e+06	1.555023e+18	8.871856e+00	5.223318e+08
std	1.331331e+06	1.689262e+17	1.986474e+01	8.494819e+07
min	3.752000e+03	1.487580e+18	-7.937000e+01	1.180452e+06
25%	5.726191e+06	1.487580e+18	2.060000e+00	4.866830e+08
50%	5.811429e+06	1.487580e+18	4.210000e+00	5.566496e+08
75%	5.859462e+06	1.487580e+18	7.140000e+00	5.828019e+08
max	5.917178e+06	2.235524e+18	3.277800e+02	5.954145e+08

2.3 Tiền xử lý - Giai đoạn 1: Làm sạch dữ liệu (Phần 1)

Xử lý trùng lặp và ngoại lệ:

- **Loại bỏ trùng lặp:** Tiến hành loại bỏ hoàn toàn các dòng trùng lặp (Drop duplicates).
- **Xóa giá âm/0:** Các bản ghi có price ≤ 0 bị loại bỏ vì không mang ý nghĩa kinh doanh.
- **Giới hạn ngoại lệ (Winsorization):** Các mặt hàng có giá lớn hơn phân vị thứ 99 (99th percentile) được giới hạn lại để giảm tác động của nhiễu.

```
1 data = raw_data.drop_duplicates()
2 data=data[data['price']>=0]
```

[13] ✓ 9.9s Python

Xử lý ngoại lệ

```
1 gioi_han_99 = data['price'].quantile(0.99)
2 print(f"Giá trị bách phân vị 99: {gioi_han_99}")
3
4 data['price'] = data['price'].clip(upper=gioi_han_99)
5
6 data.describe()
```

[12] ✓ 0.8s Python

... Giá trị bách phân vị 99: 103.17

...

	product_id	category_id	price	user_id
count	3.349409e+06	3.349409e+06	3.349409e+06	3.349409e+06
mean	5.470482e+06	1.555165e+18	8.475992e+00	5.228340e+08
std	1.336454e+06	1.690827e+17	1.519136e+01	8.527801e+07
min	3.752000e+03	1.487580e+18	0.000000e+00	1.180452e+06
25%	5.726184e+06	1.487580e+18	2.060000e+00	4.875069e+08

2.3 Tiền xử lý - Giai đoạn 1: Làm sạch dữ liệu (Phần 2)

Xử lý dữ liệu thiếu & Cột không đóng góp:

- **Điền khuyết brand:** Thay vì xóa (sẽ mất 42% traffic), giá trị Null được điền bằng "Unknown". (Sản phẩm "Không thương hiệu" cũng là đặc trưng hành vi).
- **Xóa cột nhiễu:** Xóa category_code (khuyết 98%) và user_id (không giúp phân loại phiên).
- **Xử lý session rác:** Loại bỏ các dòng có user_session bị Null (khoảng 2.2%).

```
1 data['brand'] = data['brand'].fillna('Unknown')
2 data.drop(columns='category_code',inplace=True)
3 data.drop(columns='user_id',inplace=True)
4 data=data.dropna()

[54] ✓ 0.1s Python

1 data.info()

[58] ✓ 0.0s Python

...
<class 'pandas.DataFrame'>
Index: 3348695 entries, 0 to 3533285
Data columns (total 7 columns):
#   Column      Dtype
---  ---
0   event_time  str
1   event_type  str
2   product_id  int64
3   category_id int64
4   brand       str
5   price       float64
6   user_session str
dtypes: float64(1), int64(2), str(4)
memory usage: 434.8 MB

1 data.isna().sum()/3533285*100

[60] ✓ 0.0s Python

...
event_time    0.0
event_type    0.0
product_id    0.0
category_id   0.0
brand         0.0
price         0.0
user_session  0.0
dtype: float64
```

2.4 Tiền xử lý - Giai đoạn 2: Trích xuất theo Phiên (Sessionization)

Tiền xử lý:

- **Biến mục tiêu (Target):** Gán $Y = 1$ nếu phiên có sự kiện purchase, ngược lại $Y = 0$.
- **Xóa** toàn bộ sự kiện purchase khỏi tập huấn luyện.

Tổng hợp đặc trưng:

- total_views, total_carts
- session_duration
- unique_products, avg_price, max_price


	user_session	total_carts	total_removes	\
0	00001aa1-7ee6-4d8c-81ff-bd5ce1dd1d6e	0	0	
1	00002b0e-d7f7-454e-8386-431c4021a9f6	16	8	
2	00002f36-401d-4bc5-bac6-1a683f52ac2b	0	0	
3	000035aa-dc4c-4703-aa6e-042ce96c6aef	0	0	
4	00004e6a-00f4-49e0-8ec8-f688a2e61250	0	0	

	total_views	session_duration	avg_price	max_price	unique_products	\
0	2	756.0	5.710000	5.71	1	
1	10	1485.0	4.351765	30.78	21	
2	1	0.0	2.370000	2.37	1	
3	1	0.0	4.570000	4.57	1	
4	2	749.0	7.620000	7.62	1	


	unique_brands	is_purchased
0	1	0
1	8	0
2	1	0
3	1	0
4	1	0

3.1 EDA: Phân bố nhãn (Class Imbalance)

- Dữ liệu mất cân bằng nhãn cực kỳ nghiêm trọng.
- Số lượng phiên **Không mua (0)** áp đảo hoàn toàn phiên **Có mua (1)**.
- Thách thức lớn cho các thuật toán Học máy cơ bản → Cần kỹ thuật lấy mẫu (Sampling) ở bước huấn luyện.



3.2 EDA: Phân bố đặc trưng



3.2 EDA: Các Insight từ phân bố đặc trưng

- **Insight 1 - Nhóm "Bounce"(Thoát trang nhanh):** Tập trung ở mức 1 view, 0 giây. Là nhóm click nhầm, không có tương tác.
- **Insight 2 - Xóa khỏi giỏ không phải tín hiệu xấu:** Biểu đồ `total_removes` của Lớp 1 trải dài. Điều này thể hiện sự so sánh, chọn lọc kỹ (Active Shopping) của người có ý định mua.
- **Insight 3 - Window Shopping:** Người mua hàng thường xem từ 2 đến 6 `unique_products` trước khi chốt đơn.
- **Insight 4 - Nghịch lý Giá cả:** Phân bố `avg_price` của hai Lớp chồng khít lên nhau. Giá tiền KHÔNG phải yếu tố phân loại ý định mua!

3.3 EDA: Tương quan giữa các đặc trưng

Insight Tương quan:

- **Giỏ hàng là Vua:** `total_carts` & `total_removes` tương quan dương cao nhất (0.43) với biến mục tiêu. `views` chỉ đạt 0.12.
- **Mức giá độc lập:** `avg_price` có tương quan xấp xỉ 0 với nhãn → Sẽ bị loại bỏ khi đưa vào mô hình để giảm nhiễu.
- **Đa cộng tuyến:** `session_duration` và `unique_products` tương quan rất mạnh (0.84).



4.1 Chiến lược xây dựng mô hình

Mục tiêu Đánh giá: Tập trung tối ưu **F1-Score** và **Độ phủ (Recall)** nhằm không bỏ lọt khách hàng tiềm năng.

Feature Selection: Bỏ avg_price và max_price.

Chiến lược xử lý Mất cân bằng (Ensemble-based Undersampling):

- Không Undersampling thông thường (gây mất mát thông tin Lớp 0).
- **Giải pháp:** Chia tập Lớp 0 thành 11 phần nhỏ. Ghép từng phần với toàn bộ tập Lớp 1 → Tạo 11 tập dữ liệu cân bằng.
- Huấn luyện 11 mô hình con và kết hợp kết quả (Voting/Averaging) → Giảm phương sai (Variance), tận dụng 100% dữ liệu.

5.2 Hiệu năng Mô hình Sau khi áp dụng Ensemble

1. Ensemble Cây quyết định (Random Forest + Bagging)

(Ngưỡng 0.88)

	Precision	Recall	F1-score
Lớp 0	0.98	0.96	0.97
Lớp 1	0.27	0.51	0.36

2. Ensemble LightGBM (Mô hình tốt nhất được chọn)

	Precision	Recall	F1-score
Lớp 0	0.99	0.95	0.97
Lớp 1	0.27	0.61	0.37

5.3 Đánh giá Tổng thể (Trade-off Phân tích)

- **Sức mạnh nội tại:** Ngay từ đầu, LightGBM đã áp đảo Cây quyết định (F1: 0.37 so với 0.35), chứng minh ưu thế của Tăng cường độ dốc (Gradient Boosting).
- **Hiệu năng Ensemble (Sự đánh đổi):**
 - Precision giảm nhẹ 2% (từ 0.29 $\rightarrow$ 0.27).
 - **Recall tăng vọt** 6% (từ 0.55 $\rightarrow$ 0.61). F1-Score giữ vững.
- **Ý nghĩa Kinh doanh:** Với 22.320 giao dịch Lớp 1 trong tập test, Recall tăng 6% giúp bắt trúng thêm **~ 1.339 khách hàng tiềm năng**. Vì chi phí Retargeting (Email/Push) rất rẻ, việc hi sinh 2% chuẩn xác để tăng độ phủ mang lại **Lợi nhuận ròng (Net Profit) vượt trội**.

6.1 Khuyến nghị Ra quyết định (Actionable Insights)

- ❶ **Targeted Retargeting:** Ngừng chạy Ads đại trà. Chỉ tập trung ngân sách cho tập khách hàng được gán **Nhãn 1** → Giảm CAC, tăng vọt ROAS.
- ❷ **Smart Vouchering (Phân phối mã giảm giá):**
 - Xác suất > 90%: Không cấp Voucher (Bảo vệ lợi nhuận).
 - Xác suất 70%-90%: Kích hoạt Pop-up Voucher 15 phút (Ép FOMO).
 - Xác suất < 50%: Gợi ý đọc Blog để lấy Email.
- ❸ **Real-time CS Intervention:** Bật cảnh báo cho nhân viên CSKH khi khách Nhãn 1 dừng ở trang Checkout quá 3 phút.
- ❹ **Dynamic UI/UX:** Tự động ẩn banner, đưa nút thanh toán ra giữa màn hình với nhóm có ý định mua cao.

6.2 Rủi ro & Hạn chế (Risks & Limitations)

1. Rủi ro Kinh doanh:

- Mặc dù Recall cao, Precision vẫn ở mức 27% (Có False Positives). Khuyến nghị này **chỉ an toàn với Marketing chi phí thấp** (Email, Push). KHÔNG dùng cho Telesales/Voucher quá lớn.
- Nguy cơ thao túng thuật toán (Voucher Abuse) → Cần Randomization và Rate Limiting.
- **Bắt buộc:** Cần chạy **A/B Testing** trước khi Roll-out toàn bộ.

2. Hạn chế Kỹ thuật:

- Mô hình đang đánh giá rời rạc theo từng Phiên (Session), chưa nổi được hành trình dài hạn (Cross-device/Long-term Journey).
- Bỏ qua tính tuần tự (Sequential) của chuỗi Click chuột.